DOCUMENTO TÉCNICO EJECUTIVO — VERSIÓN 2.0

# Sistema Operativo de Vida Personal

*Privacidad Absoluta · Automatización Total · Accesible para Todos*

Arquitectura de software · Ecosistema de hardware · Modelo de negocio · Roadmap de desarrollo

*Confidencial — Para presentación a capital de riesgo · México, 2026*

# 1. Resumen Ejecutivo — El Modelo Completo

Este proyecto es un sistema operativo de vida personal: una plataforma de hardware y software que permite a cualquier persona — desde un usuario doméstico hasta una corporación — tener su propia infraestructura de inteligencia artificial privada, controlada por voz o texto desde cualquier dispositivo, capaz de automatizar cualquier tarea digital sin que sus datos abandonen su perímetro físico.

La idea central en una sola oración: **ningún dato tuyo toca un servidor externo sin tu autorización explícita, y desde una conversación puedes hacer cualquier cosa que hoy requiere abrir diez aplicaciones distintas.**

## 1.1 Los Cinco Pilares

- **Hardware propio, datos propios siempre:** fotos, correos, documentos, historial médico, conversaciones — todo vive en tu dispositivo físico, cifrado, accesible desde cualquier parte del mundo vía red privada Zero Trust.
- **Una conversación que hace todo:** desde WhatsApp, Telegram, la app propia o el Companion Device, el usuario instruye al servidor en lenguaje natural. El servidor manda correos, edita videos, publica en redes, analiza datos de salud, controla computadoras, automatiza juegos, genera música y diseña gráficos.
- **Herramientas bajo demanda:** el servidor arranca con un núcleo mínimo. Cada nueva capacidad se instala en segundos desde el repositorio oficial cuando el usuario la necesita por primera vez. La comunidad contribuye nuevas herramientas constantemente.
- **Cualquier modelo de IA, con tus reglas:** modelos locales gratuitos para el trabajo cotidiano; Claude, GPT, Gemini u otros con la API key del usuario para tareas complejas. Siempre con enmascaramiento automático de datos sensibles antes de cualquier llamada externa.
- **Ecosistema escalable desde $299:** desde el Nano para cualquier persona hasta el Pro Max para corporaciones, con unidades Vault de almacenamiento expandible que se encadenan indefinidamente.

## 1.2 La Ventaja Competitiva Estructural

| Competidor | Tiene IA | Tiene hardware privado | Datos son del usuario | Precio de entrada |
|---|---|---|---|---|
| Synology | No | Sí | Sí | $300+ |
| OpenAI / ChatGPT | Sí | No | No | $20/mes |
| Apple Intelligence | Parcial | Sí | Parcial | $999+ |
| Google One AI | Sí | No | No | $2.99/mes |
| Este proyecto | Sí — local + comercial | Sí | Sí — siempre | $299 |

# 2. Ecosistema de Hardware

El hardware se divide en dos familias: nodos de cómputo (el cerebro) y unidades Vault (la memoria). Todos los dispositivos son headless — sin pantalla — y se gestionan exclusivamente desde la aplicación del usuario en sus dispositivos existentes.

## 2.1 Familia de Cómputo

| Tier | Precio venta | COGS est. | Margen | Modelos LLM locales | Para quién |
|---|---|---|---|---|---|
| Nano | $299–$349 | ~$216 | 28–36 % | Solo modelos ligeros (CLIP, Whisper, moondream2). LLM vía tokens. | Cualquier persona |
| Básico | $1,599–$1,799 | ~$1,166 | 27–35 % | Hasta 8B parámetros (Llama 3.1 8B, Qwen 2.5 7B) | Profesionales independientes |
| Intermedio | $3,799–$4,299 | ~$2,841 | 25–34 % | Hasta 34B parámetros (DeepSeek R1 32B) | PYMES, profesiones reguladas |
| Pro Standard | $7,999–$8,999 | ~$4,849 | 35–40 % | Hasta 70B parámetros (Llama 3.1 70B Q4) | Organizaciones exigentes |
| Pro Max | $17,999–$21,999 | ~$11,041 | 32–38 % | 70B–400B+, multi-usuario simultáneo | Corporativo / B2B grande |

Nota sobre TurboQuant (Google DeepMind, ICLR 2026): *la compresión de KV cache de 16 bits a 3 bits reduce los requerimientos de memoria 6 veces sin pérdida medible de precisión. Cuando esta tecnología llegue a producción en llama.cpp (estimado Q4 2026), se distribuirá vía OTA automático: el Nano podrá correr modelos de 3–4B localmente sin cambio de hardware, el Básico subirá a 13B, y el Intermedio igualará al Pro Standard actual. El Nano v2 (2027) podrá diseñarse con chip más barato, bajando el precio objetivo a $199.*

## 2.2 Familia Vault — Almacenamiento Expandible Infinito

Las unidades Vault se conectan al nodo de cómputo o entre sí mediante USB4 (40 Gbps, estándar universal). Se encadenan indefinidamente; el sistema operativo las presenta como un único volumen lógico. Se venden sin discos de datos (diskless) — el usuario compra los discos de la capacidad y marca que prefiera, manteniendo control total del costo por terabyte.

| Producto | Bahías | SSD base incluido | Precio | COGS | Margen | Caso típico |
|---|---|---|---|---|---|---|
| Vault 2 | 2 hot-swap SATA | 256 GB | $199–$229 | ~$133 | 38–42% | 2 discos 8TB en RAID 1 = 8TB con redundancia |
| Vault 4 | 4 hot-swap SATA | 256 GB | $279–$329 | ~$178 | 35–39% | 4 discos 8TB en RAID 5 = 24TB usables |
| Vault 8 | 8 hot-swap SATA | 1 TB | $449–$549 | ~$316 | 30–37% | 8 discos 20TB en RAID 6 = 120TB usables |

El Vault 4 compite directamente con el Synology DX525 (5 bahías, $479–$577, sin SSD base, protocolo propietario). El Vault 4 es 40–50% más barato, incluye SSD base, usa USB4 universal, y funciona con cualquier nodo de cómputo, no solo con hardware del mismo fabricante.

# 3. Arquitectura de Software

La pila de software se organiza en cinco capas independientes. Cada capa puede actualizarse sin afectar las demás. La filosofía de diseño es que el sistema debe poder correr el mejor componente disponible en cada momento, no el que se eligió en el lanzamiento inicial.

## 3.1 Las Cinco Capas

| Capa | Nombre | Componentes principales | Rol |
|---|---|---|---|
| 5 | Interfaces de entrada | Voz (Companion) · App unificada · WhatsApp · Telegram · Email | Cómo el usuario instruye al sistema |
| 4 | Orquestador / Cerebro | OpenClaw · PicoClaw · LangGraph · LiteLLM · Router de intención | Entiende, planifica y ejecuta |
| 3 | Herramientas y plugins | Browser · Desktop · Medios · APIs · Salud · Código · Finanzas | Lo que el agente puede hacer |
| 2 | Modelos de IA | LLM · Visión · Audio · Generación (imágenes, música, voz) | El razonamiento especializado |
| 1 | Infraestructura base | Nextcloud · Immich · NetBird · DuckDB · Chroma · Vault drivers | Los cimientos siempre activos |

## 3.2 Sistema de Plugins Bajo Demanda

Esta es la decisión arquitectónica más importante del proyecto. En lugar de instalar todas las herramientas desde el inicio, el servidor arranca con un núcleo mínimo de aproximadamente 2 GB. Cada nueva capacidad se instala únicamente cuando el usuario la necesita por primera vez.

El núcleo base siempre instalado incluye el orquestador (LangGraph + OpenClaw core), el router de modelos (LiteLLM), la gestión de archivos (Nextcloud), la red privada (NetBird), la aplicación unificada, y el sistema de plugins con verificación criptográfica.

### Flujo de instalación de un plugin

*Usuario: "Edita este video y sácame clips para Instagram"*

Orquestador: *"Para esto necesito FFmpeg + PySceneDetect + Whisper. ¿Los instalo? Ocuparán ~800MB y estarán listos en 2 minutos."*

El sistema descarga los componentes desde el repositorio oficial, verifica el hash criptográfico de cada paquete firmado por la empresa, lo instala en un container aislado, ejecuta la tarea, y

la herramienta queda disponible para futuras solicitudes. El usuario nunca interactúa con este proceso más allá de aprobar la instalación la primera vez.

### Estructura del repositorio de plugins

| Categoría | Plugins disponibles |
|---|---|
| Medios y contenido | ffmpeg-pipeline · whisper-transcription · stable-diffusion · musicgen · f5-tts · video-clipper · podcast-processor |
| Automatización web | browser-use · whatsapp-bridge · telegram-bot · instagram-agent · tiktok-agent · youtube-agent · email-agent |
| Control de dispositivos | computer-use-desktop · android-companion · adb-bridge · android-emulator (Waydroid) |
| Productividad | calendar-agent · research-agent · finance-agent · document-analyzer · code-agent |
| Diseño y creación | comfyui-workflows · inkscape-agent · freecad-agent · openscad-agent · lmms-agent |
| Salud | garmin-connector · whoop-connector · amazfit-connector · apple-health-importer · fhir-importer · dicom-storage |
| Juegos | clash-automation · game-emulator · adb-game-bridge |
| Finanzas | expense-tracker · invoice-generator · market-watcher · crypto-monitor |

La comunidad de desarrolladores puede contribuir nuevos plugins. La empresa los revisa, audita el código, y los firma criptográficamente antes de publicarlos en el marketplace oficial. Los plugins no firmados no pueden instalarse en el sistema sin que el usuario desactive explícitamente esta protección.

# 4. Modelos de Inteligencia Artificial

El sistema no depende de un único modelo. Cinco tipos de modelos especializados operan en paralelo, cada uno optimizado para su dominio. El orquestador selecciona automáticamente el modelo correcto para cada subtarea.

| Tipo de modelo | Para qué sirve | Modelos locales (gratis) | Modelos comerciales (tokens) |
|---|---|---|---|
| Lenguaje (LLM) | Razonamiento, redacción, planificación, código | Llama 3.1 70B · DeepSeek R1 · Qwen 2.5 | Claude Sonnet/Opus · GPT-4o · GPT-o3 · Gemini 2.0 |
| Visión | Ver pantallas, analizar imágenes, entender video | Qwen2.5-VL · LLaVA-Next · moondream2 (Nano) | GPT-4o Vision · Claude con imágenes |
| Audio / Transcripción | Voz a texto, identificar momentos clave en audio | Whisper large-v3 · Whisper Turbo (baja latencia) | — |
| Síntesis de voz | Texto a voz natural, clonación de voz desde muestra | F5-TTS · Coqui TTS | ElevenLabs API (opcional) |
| Generación de medios | Imágenes, música, video corto desde texto | FLUX · Stable Diffusion XL · MusicGen · AudioCraft | Midjourney API · Suno API (opcional) |

## 4.1 Enrutamiento y Privacidad — Cómo se Protegen los Datos

Cuando una tarea requiere un modelo comercial externo (Claude, GPT, Gemini), el sistema aplica automáticamente el siguiente proceso antes de que cualquier dato salga del hardware:

- El motor de enmascaramiento (XLM-RoBERTa + reglas regex) identifica toda la información sensible en la consulta: nombres, números de identificación, datos financieros, información médica.
- Los datos sensibles se reemplazan por marcadores semánticos consistentes (por ejemplo, <PERSONA_1_FEMENINO>, <MONTO_FINANCIERO_2>).
- La consulta purificada se envía al modelo externo. El proveedor nunca ve los datos reales.
- La respuesta llega con los mismos marcadores. El sistema los reemplaza localmente con los datos originales antes de mostrar el resultado al usuario.

Nota sobre modelos locales y seguridad: *el usuario puede elegir libremente qué modelos locales instala. La empresa no restringe las opciones. Sin embargo, el sistema de plugins bajo demanda y la verificación criptográfica garantizan que cualquier modelo instalado desde el*

*repositorio oficial ha sido auditado previamente. El usuario que instala modelos externos al repositorio lo hace bajo su propia responsabilidad.*

# 5. Capacidades de Automatización

## 5.1 Control de Cuentas y Aplicaciones

El agente puede controlar cualquier cuenta web o aplicación a través de tres mecanismos complementarios. El usuario otorga permisos una sola vez desde el panel de la app; el agente los usa hasta que el usuario los revoque.

### Mecanismo 1 — Control de navegador (Browser Use + Playwright)

El servidor corre Chromium headless. El agente navega, rellena formularios, sube archivos, y publica contenido en cualquier sitio web. Funciona con Gmail, Instagram, Facebook, LinkedIn, X, TikTok, portales bancarios, tiendas en línea, y cualquier interfaz web.

### Mecanismo 2 — Control de escritorio (Computer Use)

Una app compañera instalada en Windows, macOS o Linux expone la pantalla y el control de input al servidor vía WireGuard. El modelo de visión toma screenshots periódicos para verificar el estado de la interfaz. El agente puede operar cualquier software instalado — incluyendo software propietario con licencia del usuario como Adobe Premiere, AutoCAD, o cualquier DAW.

### Mecanismo 3 — Control de Android (Servicios de Accesibilidad + Emulador)

En dispositivos Android físicos del usuario, la app compañera activa los Servicios de Accesibilidad para dar al agente visibilidad y control de cualquier app instalada. Para casos como automatización de juegos o apps con restricciones, el servidor puede correr un emulador Android (Waydroid) directamente, sin necesitar el teléfono físico del usuario.

### Vinculación de WhatsApp sin pantalla

El servidor genera el código QR internamente y lo envía como imagen a la app del usuario en su teléfono. El usuario lo escanea desde ahí con la app de WhatsApp (Dispositivos vinculados). La sesión persiste indefinidamente. El mismo mecanismo aplica para cualquier servicio que use autenticación por QR.

## 5.2 Producción de Contenido para Creadores

Este es uno de los casos de uso de mayor impacto del sistema. Un artista, podcaster, o creador de contenido puede convertir una grabación larga en una semana de contenido publicado en múltiples plataformas, sin saber editar video ni tener equipo especializado.

### Pipeline de video automático

- Whisper transcribe el audio completo con timestamps por frase y nivel de energía del audio.
- PySceneDetect identifica cortes de cámara y cambios de iluminación en el video.
- El LLM cruza ambos análisis y selecciona los momentos más relevantes según los criterios del usuario (cantidad de clips, duración, plataforma objetivo).
- FFmpeg corta los clips y los reformatea automáticamente: 9:16 para TikTok e Instagram Reels, 16:9 para YouTube, 1:1 para posts.
- Se queman subtítulos automáticos en el video.
- El LLM genera un caption distinto y optimizado para cada plataforma y clip.
- El usuario aprueba y el sistema publica con el espaciado temporal que defina (uno por día, tres por semana, etc.).

### Pipeline de podcast

- Transcripción completa con timestamps.
- Identificación automática de las 5–10 citas más impactantes.
- Generación de audioclips + imagen con la cita en texto + subtítulos quemados.
- Resumen del episodio para newsletter.
- Título SEO-optimizado para YouTube.
- Todos los assets listos para aprobación o publicación directa.

# 6. Ecosistema de Salud Personal

El servidor actúa como el primer repositorio de salud personal soberano: el usuario es el único custodio de sus datos médicos. La estrategia regulatoria es posicionar el dispositivo como herramienta de cómputo personal, no como sistema de información de salud regulado, replicando el modelo de Signal en mensajería. Esto permite expansión global sin fricción regulatoria país por país.

| Fuente de datos | Datos disponibles | Integración |
|---|---|---|
| Garmin Connect | HRV, $VO_2$max, carga de entrenamiento, fases de sueño | API REST oficial + OAuth 2.0 |
| Amazfit / Zepp Health | $SpO_2$, PAI Score, sueño REM, frecuencia cardíaca | API REST oficial + OAuth 2.0 |
| Apple Health (iPhone) | Todos los datos del ecosistema Apple | Importación XML local — sin API, sin nube |
| Google Fit | Actividad física, frecuencia cardíaca, peso | API REST (Android) |
| Whoop | HRV, recuperación, carga cardiovascular, ciclos de sueño | API REST + OAuth 2.0 |
| Oura Ring | Preparación diaria, temperatura corporal, sueño de alta precisión | API REST + OAuth 2.0 |
| Dexcom G7 / Libre 3 | Glucosa continua en tiempo real | NFC export + Open Source Uploader |
| Estudios clínicos (PDF/FHIR) | Laboratorios, imagenología, consultas médicas | Carga manual por el usuario al servidor |

El servidor MCP de salud actúa como capa de traducción semántica entre la base de datos local (DuckDB + TimescaleDB) y el agente de IA. El usuario puede consultar en lenguaje natural la correlación entre sus biomarkers, recibir alertas proactivas de anomalías, y exportar un expediente FHIR R4 para compartir con su médico — con su consentimiento explícito.

# 7. Companion Device — La Interfaz de Conversación Total

El Companion Device es la capa de experiencia más avanzada del ecosistema: un dispositivo de audio y cámara que permite conversación en tiempo real con el servidor desde cualquier lugar, sin pantalla ni teclado. El usuario habla; el servidor actúa.

## 7.1 Cómo Funciona

El wake word (palabra de activación) se procesa localmente en el chip del Companion — ningún audio se transmite al servidor hasta que el usuario activa el dispositivo. Una vez activado, el audio viaja cifrado al teléfono del usuario, que lo retransmite al servidor vía WireGuard. Whisper transcribe en tiempo real, el LLM razona y actúa, F5-TTS genera la respuesta en voz, y el usuario la escucha en menos de 800ms desde que termina de hablar.

## 7.2 Capacidades

- Consultas de calendario, correo, documentos y datos de salud — respondidas en voz.
- Instrucciones de automatización — "mándale a Juan que llego tarde" — ejecutadas de inmediato.
- Identificación visual — apuntar la cámara a una planta, un texto, o una pantalla para que el modelo de visión lo analice.
- Control de dispositivos y aplicaciones — todo lo descrito en el capítulo de automatización, iniciado por voz.
- Conversación de contexto amplio — el agente recuerda el hilo de la conversación a lo largo del día, no solo del último mensaje.

# 8. Modelo de Negocio

## 8.1 Tres Fuentes de Ingreso Complementarias

### Venta de Hardware — Margen inmediato

La venta de nodos de cómputo y unidades Vault genera el ingreso inicial con márgenes de 25–42%. La manufactura en el Triángulo de Oro industrial de México bajo T-MEC reduce costos arancelarios en exportaciones a EUA y Canadá, y el acceso a asignación OEM de GPU directamente con NVIDIA (a volúmenes de 500+ unidades/trimestre) garantiza precios cercanos al MSRP independientemente del mercado retail.

### Tokens de IA — Ingreso recurrente automático

Cuando el usuario usa un modelo externo, la empresa añade un margen sobre el costo base del proveedor. El consumo se mide y firma criptográficamente mediante el chip TPM 2.0, y se factura automáticamente via OpenMeter y Stripe. El usuario no puede manipular el contador de tokens sin que el sistema lo detecte. Un millón de usuarios activos con consumo promedio de $5 USD/mes en tokens generan $2M USD de ingreso recurrente mensual de esta fuente sola.

### Licencias B2B — Contratos anuales predecibles

Las funciones empresariales (gestión de flotas de dispositivos, auditorías de cumplimiento, firmware certificado por TPM, soporte 24/7 con SLA) son propietarias y vinculadas al número de serie del hardware. El software base es open source y construye la comunidad; las capas empresariales son el negocio. Este modelo Open Core crea un foso defensivo: los competidores pueden copiar el software, pero no pueden replicar el hardware certificado ni los márgenes de manufactura.

## 8.2 Valor de Vida del Cliente (LTV)

| Segmento | Compra inicial | Expansión típica (12m) | Tokens/mes | LTV 3 años est. |
|---|---|---|---|---|
| Usuario Nano | $299–$349 | + Vault 2 (~$220) | $2–8 USD | $600–$900 |
| Profesional Básico | $1,599–$1,799 | + Vault 4 (~$300) | $0–5 USD | $2,000–$2,500 |
| Empresa Intermedio | $3,799–$4,299 | + Vault 4–8 (~$500) | $15–50 USD | $5,000–$7,000 |
| Org. Pro Standard | $7,999–$8,999 | + Vault 8 x2 (~$1,000) | $50–150 USD | $11,000–$15,000 |
| Corp. Pro Max | $17,999–$21,999 | + Vault 8 x4 + SLA | $200–500 USD | $30,000–$45,000 |

La escalera de valor: el usuario entra por el Nano a $299, en seis meses añade un Vault, en un año usa tokens regularmente, en dos años migra a un tier superior. El LTV crece con el tiempo sin que el costo de adquisición aumente.

# 9. Arquitectura de Ciberseguridad

El sistema implementa defensa en profundidad con nueve capas independientes. El compromiso de cualquier capa individual no compromete las subyacentes. El usuario es legalmente el custodio responsable de sus datos y de las acciones que autoriza al agente — el sistema provee las herramientas; la responsabilidad del uso es del usuario, análogo al modelo de Signal.

| Capa | Mecanismo | Estado |
|---|---|---|
| Física / Firmware | TPM 2.0 + Secure Boot — atestación criptográfica del kernel antes de ejecutarlo | Implementado |
| Sistema Operativo | Linux hardened con SELinux/AppArmor — least-privilege por servicio; cada componente en namespace propio | Roadmap Q1 |
| Datos en reposo | LUKS2 con Argon2id — cifrado de volumen completo; clave derivada del TPM | Roadmap Q1 |
| Red local (LAN) | VLAN dedicada para el servidor; TLS 1.3 mutual incluso en red doméstica | Roadmap Q1 |
| Red externa (WAN) | WireGuard P2P vía NetBird autohospedado — ChaCha20-Poly1305 + Curve25519 | Implementado |
| PII en tránsito | XLM-RoBERTa + regex — enmascaramiento antes de todo egress a APIs externas | Implementado |
| Agentes de IA | Sandbox seccomp + AppArmor para OpenClaw/PicoClaw — aprobación del usuario en acciones irreversibles | Roadmap Q2 |
| Autenticación | FIDO2/WebAuthn + biométrico en cliente + PIN cifrado por TPM para recuperación | Parcial |
| Cadena de suministro | Reproducible builds del firmware; hash publicado en registro inmutable | Roadmap Q2 |

# 10. Roadmap de Desarrollo — 60 Semanas

El principio de priorización es que cada fase debe producir algo que un usuario real pueda usar, y que sirva como demo para la siguiente ronda de financiamiento. El desarrollo se hace con el modelo de IA asistida: cada ingeniero usa Claude Code o equivalente como par de programación constante, multiplicando la productividad individual por 5–10x frente al desarrollo tradicional.

| Fase | Semanas | Nombre | Entregable para el usuario | Demo para inversores |
|---|---|---|---|---|
| 0 | 1–4 | Fundamentos | Sincronización de archivos desde cualquier red | Infraestructura validada |
| 1 | 5–12 | MVP Conversacional | Hablar con tus archivos desde Telegram | Demo Seed Round |
| 2 | 13–24 | Automatización Base | Agente que manda correos y WhatsApps por instrucción | Demo Serie A |
| 3 | 25–36 | Producción de Contenido | Video de 2h → 15 clips publicados en redes automáticamente | Demo Serie B |
| 4 | 37–48 | Computer Use Completo | Control de cualquier app, juego, software instalado | Producto completo (software) |
| 5 | 49–60 | Companion y Salud | Conversación en tiempo real + análisis de salud completo | Producto completo |

## 10.1 Equipo Mínimo para Arrancar

Para las Fases 0 y 1 se necesitan exactamente tres personas:

- **Ingeniero de infraestructura (Linux senior + networking + seguridad):** levanta el servidor base, Docker, NetBird, Nextcloud, y el sistema de plugins.
- **Ingeniero ML/backend (Python senior + experiencia en LLMs):** integra Ollama, Whisper, LiteLLM, LangGraph, y construye el primer agente funcional.
- **Desarrollador full-stack (React/TypeScript + mobile básico):** construye la app unificada y el bot de Telegram.

Con estas tres personas y el modelo de desarrollo asistido por IA, el demo del Seed Round está listo en 12 semanas.

## 10.2 El Repositorio como Artefacto Vivo

Todo el desarrollo se hace en abierto en GitHub desde el primer día. Esto cumple tres funciones simultáneas: cualquier VC técnico puede auditar que el código es real; la comunidad de desarrolladores puede contribuir plugins antes de que el producto esté terminado; y la IA (Claude Code, Cursor, Copilot) puede leer el repositorio en cualquier momento y continuar el trabajo desde donde se dejó sin perder contexto.

La IA puede hoy escribir el código de integración de dos librerías existentes, configurar el stack de Docker, implementar el bot de Telegram con LangGraph, y construir el sistema de plugins con verificación de hash. Lo que no puede reemplazar es la toma de decisiones arquitectónicas ante ambigüedad, el diseño de la arquitectura de seguridad del firmware, y la validación final de que el sistema cumple sus promesas de privacidad. Esas decisiones requieren ingenieros humanos con criterio.

# 11. Recuperación ante Desastres y Conectividad Global

## 11.1 Arquitectura de Backup — Tres Capas

- **Capa 1 — Snapshot local inmutable:** BTRFS con Copy-on-Write, snapshots incrementales cada 15 minutos. Recuperación de cualquier archivo en menos de 2 minutos.
- **Capa 2 — Replicación a segundo nodo:** sincronización P2P cifrada vía libp2p con TLS 1.3 en tránsito y AES-256-GCM en reposo. La clave nunca sale del dispositivo origen.
- **Capa 3 — Backup distribuido zero-knowledge:** codificación de borrado Reed-Solomon (esquema 29-de-80). Cada fragmento cifrado con HKDF-SHA256 se distribuye entre nodos heterogéneos. Ningún proveedor individual puede reconstruir nada. La clave maestra se divide mediante Shamir's Secret Sharing. El software de recuperación es open source bajo MPL-2.0 — si la empresa fabricante desapareciera, el usuario recupera sus datos con herramientas de terceros.

## 11.2 Solución CGNAT y eSIM

El 60–70% de los usuarios residenciales en México opera bajo CGNAT (sin IP pública propia). El sistema resuelve esto con dos mecanismos:

- **Servidor relay STUN/TURN (Coturn) autohospedado:** coordina el establecimiento de túneles WireGuard sin actuar como intermediario del tráfico real. Costo operativo de $4–6 USD/mes por servidor para cientos de dispositivos.
- **Módulo eSIM integrado en todos los dispositivos:** otorga al servidor su propia identidad de red permanente e independiente del proveedor de Internet del usuario. Consumo de datos: 50–100 MB/mes solo de señalización. Costo operativo: $1–2 USD/dispositivo/mes en planes M2M.

# 12. Manufactura en México

La manufactura en México no es una decisión logística: es una ventaja competitiva estructural. El T-MEC otorga acceso preferencial al mercado norteamericano con aranceles de 0% para manufactura con contenido regional suficiente. El Triángulo de Oro industrial distribuye la producción por especialización:

- **Guadalajara, Jalisco:** ingeniería de hardware y fabricación de PCB. Presencia de Flex, Sanmina y proveedores especializados en SMT de precisión para chips TPM, módulos eSIM y FPGAs.
- **Monterrey, Nuevo León:** ensamblaje electromecánico final (Box Build), integración de chasis y logística transfronteriza hacia distribuidores en EUA.
- **Ciudad de México:** centro de talento de software, capital institucional, y sede de operaciones de ventas B2B.

El financiamiento no dilutivo de SECIHTI (3–5 millones de pesos para proyectos en TRL 3–4) puede acelerar la validación del controlador FPGA para el módulo SD RAID y la certificación del hardware con TPM 2.0 sin dilución de los fundadores.

# 13. Equipo Requerido

| Perfil | Prioridad | Responsabilidad | Stack clave |
|---|---|---|---|
| Ingeniero Hardware Embebido | CRÍTICO | Diseño PCB, componentes, gestión térmica, certificaciones FCC/NOM | Altium, KiCad, SPICE, ARM BSP |
| Ingeniero Firmware / BSP | CRÍTICO | Board Support Package, TPM 2.0, Secure Boot, driver RAID del FPGA | C / Rust, Linux Kernel, UEFI, TPM TSS |
| Ingeniero Ciberseguridad | CRÍTICO | Modelo de amenazas, hardening del OS, sandbox de agentes, auditoría | SELinux, LUKS2, WireGuard, seccomp, FIDO2 |
| ML Engineer — Inferencia | ALTA | Optimización de modelos, cuantización, benchmarking, backends | CUDA, llama.cpp, Ollama, vLLM, GGUF |
| NLP Engineer — PII | ALTA | Fine-tuning XLM-RoBERTa para entidades mexicanas, pipeline de enmascaramiento | Transformers HF, spaCy, Presidio |
| Full-Stack — Uno Platform | ALTA | App multiplataforma: archivos, bóveda fotográfica, chat, salud | C# / .NET 9, Uno Platform, WebAssembly |
| DevOps / Platform Engineer | ALTA | Orquestación de contenedores, OTA firmado, sistema de plugins, CI/CD | Docker rootless, Podman, OpenMeter, Ansible |
| AI Agent Engineer | FASE 2 | Workflows OpenClaw, plugins, memoria del agente, sandbox | LangGraph, MCP Protocol, OpenClaw, Whisper |
| Especialista Datos de Salud | FASE 2 | FHIR R4, pipelines de wearables, servidor MCP de salud | FHIR, DICOM, DuckDB, TimescaleDB |
| Business Development B2B | FASE 1 | Licenciamiento Open Core, SLAs, relaciones EMS en GDL/MTY | Licenciamiento HW, SaaS B2B, T-MEC |
| Asesor Legal — Privacidad | FASE 1 | LFPDPPP, GDPR, licencias MIT/propietarias, responsabilidad del usuario | LFPDPPP, GDPR, OSS Licensing |

# 14. Conclusión — Por Qué Este Proyecto, Por Qué Ahora

Tres macrotendencias convergentes crean la ventana de oportunidad:

- **La demanda de privacidad de datos ha alcanzado un máximo histórico.** Los usuarios son conscientes de que sus datos son el producto en los ecosistemas comerciales actuales. El mercado busca activamente alternativas.
- **Los modelos de lenguaje open source han alcanzado paridad funcional con los servicios comerciales.** Llama 3.1 70B y DeepSeek R1 son competitivos con GPT-4 en la mayoría de tareas. Por primera vez en la historia, un individuo puede tener el mismo poder cognitivo que una corporación en su propio hardware.
- **El nearshoring en México crea condiciones únicas.** T-MEC, ecosistema industrial maduro en Guadalajara y Monterrey, y capital de riesgo local con apetito por modelos deep tech con hardware propio.

Las decisiones técnicas fundamentales son correctas y verificables: WireGuard/NetBird, TPM 2.0, LiteLLM, rclone, LangGraph, BTRFS/Reed-Solomon son tecnologías maduras con implementaciones de producción probadas. El sistema de plugins bajo demanda reduce el riesgo de ejecución inicial y permite que la comunidad expanda las capacidades del producto más rápido de lo que cualquier equipo interno podría hacerlo.

El modelo de negocio es técnicamente blindado: los tokens firmados por TPM no pueden manipularse, las licencias B2B están vinculadas al hardware, y el Open Core construye comunidad mientras las capas empresariales generan ingresos predecibles. El ecosistema completo — desde el Nano a $299 hasta el Pro Max a $21,999, pasando por las unidades Vault y el Companion Device — crea una plataforma de adopción masiva con LTV que crece con el tiempo.

Índice de viabilidad técnica y diferenciación: **8.2 / 10.** Las brechas identificadas son resolubles en 3–4 meses de ingeniería. Con el equipo correcto y una ronda semilla adecuada, este sistema tiene la capacidad de convertirse en la infraestructura de privacidad personal de referencia para América Latina y el mercado hispano de América del Norte, con proyección a mercados globales donde la soberanía de datos es un derecho que nadie ha logrado democratizar todavía.

*— Fin del documento — Versión 2.0 — México, 2026*